

Speech de présentation

Bank Marketing · M1 ESGIS · Analyse et visualisation des données en Python

Durée totale visée	~ 15 minutes hors démo
Slides	22
Dataset	UCI Bank Marketing · 45 211 × 17
Tests stats	Student (Q2) · Chi ² (Q3) · Pearson (Q4)
Livrables	Notebook · Streamlit · Dash · Plotly Studio

Mode d'emploi. Chaque slide est annotée d'un temps indicatif et d'un speech court. Le speech est rédigé pour être dit, pas lu mot à mot — approprie-le-toi avant l'exposé.

SLIDE 01 · 30 s

Cover — Finances sous la loupe

Bonjour. Je suis Tony Stark, M1 Architecture Logiciels. Aujourd'hui je vous présente une analyse complète de la campagne marketing d'une banque portugaise — 45 211 conversations, 17 variables, 4 questions et 3 tests statistiques. L'objectif : comprendre ce qui pousse un client à dire oui à un dépôt à terme.

■ **Respire. Pose le décor avec calme avant d'enchaîner.**

SLIDE 02 · 20 s

Sommaire — Le parcours en 6 étapes

Le plan est simple : on pose le contexte, on découvre le dataset, on l'explore, on répond à quatre questions précises avec des tests, et on termine par les décisions actionnables et la démo des dashboards.

SLIDE 03 · 10 s

Section 01 — Contexte

Première section : pourquoi ce dataset ?

SLIDE 04 · 45 s

Problématique

La question centrale est la suivante : « Quelles caractéristiques du client et de l'appel sont associées au succès d'une souscription ? ». Une banque qui passe 45 000 appels veut savoir où concentrer ses efforts. Notre rôle d'analyste : transformer ce CSV en quatre réponses opérationnelles.

■ **Insiste sur le mot 'opérationnelles' — c'est ce qui distingue analyse et reporting.**

SLIDE 05 · 10 s

Section 02 — Le dataset

Place au dataset.

SLIDE 06 · 40 s

Volumétrie

Le dataset UCI Bank Marketing couvre 45 211 clients sur la période 2008-2013. 17 variables, zéro valeur manquante, séparateur point-virgule — petit piège classique du CSV européen. La cible est binaire : `y` vaut yes ou no.

■ **Si le prof demande la source : UCI Machine Learning Repository, dataset Bank Marketing de Moro et al.**

SLIDE 07 · 40 s

Méthode — Du CSV à la décision

La méthode en sept étapes : on charge le CSV avec pandas, on nettoie et on recode, on explore par statistiques descriptives et visualisations, on pose des hypothèses, on les teste avec scipy, on visualise les résultats avec Plotly, et on conclut par des recommandations.

■ **Si on te demande pourquoi pas un modèle ML : car le brief est descriptif, pas prédictif. Et duration serait une fuite de données pour de la prédiction.**

SLIDE 08 · 10 s

Section 03 — Exploration

Section trois : la première lecture du dataset.

SLIDE 09 · 45 s

Cible — Une décision sur huit est un oui

Premier constat fondamental : seulement 11.7 % de souscriptions, soit 5 289 oui pour 39 922 non. C'est un dataset déséquilibré. Cela aura deux conséquences : il faut éviter les pièges visuels — un camembert classique écraserait la classe minoritaire — et toute modélisation prédictive devra gérer ce déséquilibre.

■ Si on te parle d'accuracy : dis qu'avec ce déséquilibre, prédire toujours 'no' donne 88 % d'accuracy mais zéro valeur business.

SLIDE 10 · 30 s

Petite pause — Selon vous, qui souscrit le plus ?

Petit moment interactif avant de répondre. Cadres, retraités, étudiants ou ouvriers ? Prenez deux secondes... la réponse arrive juste après.

■ Regarde le public, ralentis. C'est une slide d'engagement.

SLIDE 11 · 10 s

Section 04 — Quatre questions

Section quatre : on attaque les questions une par une.

SLIDE 12 · 50 s

Question 01 · Profil — Qui souscrit vraiment ?

La réponse était C : les étudiants. 28.7 % d'entre eux souscrivent, suivis des retraités à 22.8 %. Tout en bas, les ouvriers à 7.3 %. Trois variables expliquent l'essentiel : le métier, le statut marital et l'éducation. L'âge dessine ensuite deux populations distinctes — on y revient dans deux slides.

SLIDE 13 · 40 s

Q1 · Détail — Le métier domine tout

Un étudiant est quatre fois plus susceptible de souscrire qu'un ouvrier. Cet écart énorme au sein d'une seule variable nous dit que segmenter la campagne par métier est probablement la décision la plus rentable.

SLIDE 14 · 40 s

Q1 · Âge — Deux populations

L'âge révèle deux pics de souscription : les jeunes entre 25 et 30 ans, qui sont nos étudiants, et les seniors au-delà de 60 ans, qui sont nos retraités. Entre les deux, la classe active est largement en dessous. C'est un insight clé pour cibler les messages publicitaires.

SLIDE 15 · 50 s

Question 02 · Solde — Les souscripteurs sont-ils plus riches ?

Hypothèse : les clients qui souscrivent ont un solde bancaire plus élevé. Test de Student de Welch — on compare deux moyennes sur des échantillons indépendants avec variances inégales. Résultat : solde moyen 1 304 € chez les non-souscripteurs contre 1 804 € chez les souscripteurs. t vaut 9.93, p -value de l'ordre de 10^{-23} . On rejette H_0 sans hésiter : la différence est très significative.

■ Si on demande pourquoi Welch et pas Student classique : car les variances des deux groupes ne sont pas égales (test de Levene).

SLIDE 16 · 50 s

Question 03 · Catégoriel — Quelles variables comptent ?

Question trois : on teste l'indépendance entre chaque variable catégorielle et la cible, avec le test du χ^2 . Sept variables passées au crible : métier, marital, éducation, prêt immobilier, prêt conso, défaut, contact. Toutes ressortent avec p inférieur à 0.001. Classées par force : le métier domine, suivi du type de contact et du prêt immobilier.

■ Le χ^2 mesure l'écart entre fréquences observées et attendues sous indépendance. p très petit = on rejette l'indépendance.

SLIDE 17 · 50 s

Question 04 · Appel — Quand ça marche, à quoi ça tient ?

Dernière question : qu'est-ce qui rend un appel efficace ? Test de corrélation de Pearson entre la durée de l'appel et la souscription. r vaut 0.395, p quasi nul. La médiane de durée passe de 164 secondes pour les refus à 426 secondes pour les souscriptions — un facteur 2.6. Attention : la durée n'est connue qu'après l'appel, donc c'est un indicateur descriptif, pas un levier prédictif.

■ Insiste sur la nuance descriptif vs prédictif — c'est la question piège classique.

SLIDE 18 · 10 s

Section 05 — Décisions

Dernière section : ce qu'on retient pour les prochaines campagnes.

SLIDE 19 · 60 s

Recommandations — 4 leviers actionnables

Quatre recommandations concrètes. Un : cibler en priorité les étudiants, les retraités, les célibataires diplômés et les clients sans prêt immobilier avec un solde supérieur à la médiane. Deux : former les commerciaux à tenir l'appel — la durée corrèle fortement. Trois : privilégier le contact mobile sur le téléphone fixe. Quatre : éviter de relancer plus de trois fois — au-delà, le taux de réussite chute.

SLIDE 20 · 45 s

Limites — L'honnêteté de l'analyste

Trois limites à reconnaître. Le déséquilibre 88-12 biaiserait toute modélisation naïve. La durée d'appel est connue a posteriori — elle explique sans permettre de prédire. Et les données datent de 2008-2013 : le contexte économique post-crise n'est pas forcément représentatif d'aujourd'hui.

■ Montrer les limites = signe de maturité analytique. Le prof adore.

SLIDE 21 · 60 s

Stack de visualisation

Avant de conclure, un mot sur les outils. Six briques couvrent tout le cycle : pandas pour le chargement et le traitement, matplotlib et seaborn pour les graphes statiques du rapport, Plotly pour l'interactivité dans le notebook, Streamlit pour un dashboard rapide à filtres, Dash pour une application web structurée avec callbacks, et Plotly Studio pour itérer visuellement sans toucher au code. Chaque outil joue un rôle complémentaire.

■ Si on demande la différence Streamlit vs Dash : Streamlit ré-exécute tout le script à chaque clic, Dash a des callbacks granulaires.

SLIDE 22 · 120 s + démo

Démo live · Et questions

On bascule sur la démo. Je lance le notebook pour montrer l'analyse complète, puis Streamlit pour le dashboard filtres-KPI, puis Dash en parallèle pour comparer les deux approches, et enfin un export Plotly Studio pour montrer l'édition no-code. Je vous remercie pour votre attention — place à vos questions.

■ Ouvre déjà les 3 onglets terminal AVANT de lancer la présentation. Commandes : ``streamlit run app/app.py`` puis ``python dash_app/app_dash.py``.

Anti-sèche — chiffres à ne pas hésiter

45 211	Lignes du dataset
17	Variables
11.7 %	Taux global de souscription
5 289 / 39 922	Souscriptions / refus
28.7 %	Taux chez les étudiants (max)
7.3 %	Taux chez les ouvriers (min)
1 304 € → 1 804 €	Solde moyen Refus → Souscription
t = 9.93 ; p ≈ 4.4e-23	Test de Student sur le solde
Chi² toutes p < 0.001	7 variables catégorielles
r = 0.395 ; p ≈ 0	Pearson durée × souscription
164 s → 426 s (× 2.6)	Médiane durée Non → Oui

Commandes de démo à préparer avant de monter sur scène

jupyter notebook notebook/analyse.ipynb

streamlit run app/app.py

python dash_app/app_dash.py

Plotly Studio → ouvrir <https://plotly.com/studio/> → Import →
plotly_studio/01_taux_par_metier.json